

Capítulo II - Revisión y Fundamentación Teórica

1.1. Antecedentes

En esta sección se define la estrategia de búsqueda que se aplicó para buscar los antecedentes, los filtros para la selección de los documentos de investigación, la extracción de contenido de los documentos finalistas y por último una discusión sobre estas.

1.1.1. Estrategia de búsqueda

La estrategia de búsqueda se inició definiendo el tema central de investigación, la problemática y la propuesta de solución. A partir de ello, se identificaron los componentes principales: Derecho (ámbito legal) e Inteligencia Artificial (IA, agentes inteligentes, chatbots, asistentes virtuales). El componente de Ingeniería de Software se consideró de forma implícita, dado que aparece en la etapa de implementación pero no constituye el núcleo de los estudios revisados.

Con estos 3 bloques definidos, se elaboró la **cadena de búsqueda** base en inglés, orientada a bases de datos internacionales (Scopus, IEEE Xplore, Google Scholar):

TITLE-ABS-KEY(

("intelligent agent" OR "AI agent*" OR "artificial intelligence agent*" OR "legal chatbot*" OR "legal assistant*" OR "virtual legal advisor*" OR "conversational agent*")*

AND

("legal system" OR "legal domain" OR "legal practice" OR "legal consultation" OR "legal reasoning" OR "legal informatics" OR "legal judgment prediction" OR "LJP" OR "case outcome prediction" OR "legal decision support" OR "legal advice system*" OR "automated legal service*")*

AND

("system" OR "software" OR "platform" OR "framework" OR "architecture" OR "module" OR "component" OR "development" OR "engineering")

) AND PUBYEAR > 2015 AND PUBYEAR < 2027

AND (LIMIT-TO (DOCTYPE,"cp") OR LIMIT-TO (DOCTYPE,"ar") OR LIMIT-TO (DOCTYPE,"ch"))

Posteriormente, esta cadena tuvo variaciones, principalmente reducciones y traducciones al español, con el fin de ampliar la búsqueda hacia tesis y documentos académicos de repositorios peruanos.

1.1.2. Especificación de las bases de datos empleadas

1. Scopus: Base de datos bibliográfica internacional de artículos científicos, conferencias y capítulos de libros revisados por pares.
2. Repositorios institucionales
 - a. ALICIA: Repositorio nacional de acceso abierto del CONCYTEC, que centraliza la producción científica del Perú.
 - b. Universidad La Salle: Repositorio institucional con acceso a tesis y trabajos académicos de sus estudiantes e investigadores.
 - c. Universidad Católica Santa María: Repositorio institucional que reúne tesis de pregrado, posgrado e investigaciones académicas.
 - d. Universidad Católica San Pablo: Repositorio institucional con publicaciones y tesis desarrolladas en sus programas académicos.
 - e. Universidad Nacional de San Agustín:
Repositorio institucional que alberga tesis de grado, posgrado e investigaciones científicas de la UNSA.
 - f. Universidad de Lima:
Repositorio institucional con acceso a tesis, investigaciones y publicaciones académicas de sus facultades.
 - g. Pontificia Universidad Católica del Perú:
Repositorio institucional con tesis, artículos y publicaciones de investigación de la comunidad académica PUCP.

1.1.3. Criterios de búsqueda

3. Idioma: inglés y español (para abarcar tanto literatura internacional como tesis y publicaciones nacionales).
4. Periodo: desde el año 2015 hasta la actualidad (últimos 10 años).
5. Tipo de documentos: artículos de revistas científicas, ponencias en conferencias, capítulos de libros y tesis académicas (cuando provienen de repositorios universitarios).
6. Acceso: documentos con disponibilidad de texto completo.
7. Enfoque Temático: documentos con disponibilidad de texto completo.
8. Bases de datos consultadas: Scopus, repositorios institucionales, ALICIA y repositorios de universidades peruanas.

1.1.4. Selección de los trabajos

- ii. Prefiltro: se aplicó los criterios de búsqueda ya definidos anteriormente(a.ii) y se encontraron **10 tesis y 50 artículos**.

- iii. Filtro por título: se identificaron **6 tesis** y **35 artículos** que en primera instancia guardaban relación con la temática.
- iv. Filtro por abstract: de estos, se seleccionaron **5 tesis** y **16 artículos**, de los cuales **10** presentaron una relación directa con el objeto de estudio y **6** fueron considerados de apoyo.
- v. Filtro por contenido: finalmente, tras la revisión integral, se incluyeron **0 tesis** y **11 artículos** que conforman la base de antecedentes de la investigación.
- vi. Diagrama de flujo del filtrado, como se muestra en la figura 2.




Figura 2. Diagrama de flujo del filtrado de documentos de investigación como parte de los antecedentes.

Fuente: Elaboración propia.

1.1.5. Extracción de contenido

Se extrajeron las partes más sustanciales (Problemática, Solución Resultados y Conclusiones) de los 11 documentos seleccionados entre artículos y tesis.

1. **[Tipo de Documento]:** Artículo **[Título]:** AgentsBench: A Multi-Agent LLM Simulation Framework for Legal Judgment Prediction [3]

[Problemática] Las técnicas actuales de Inteligencia Artificial (IA) para la Predicción de Sentencias Legales (LJP) se enfocan principalmente en el resultado, sin lograr reflejar el proceso deliberativo real del sistema judicial, que incluye debate y consenso entre jueces. Esta carencia provoca modelos que sufren de sesgos, falta de explicabilidad y no incorporan adecuadamente las implicaciones éticas y sociales, aspectos críticos para la transparencia de la justicia digital.

[Solución] Para incorporar la naturaleza colectiva de un juicio, se propuso AgentsBench, un

sistema de simulación con múltiples agentes de inteligencia artificial. Este sistema replica un tribunal colegiado inspirado en el modelo chino de jueces legos, e incluye tanto jueces profesionales como ciudadanos comunes. Su funcionamiento se divide en cuatro etapas: primero se forma el tribunal, después cada uno da su fallo inicial de manera individual, luego hay una deliberación donde todos discuten en grupo, y al final se toma la decisión definitiva. Los agentes se configuran para actuar según estándares jurídicos o representar valores de la comunidad. **[Resultados]** Al evaluar la tarea de predecir condenas privativas de libertad usando datos de LawBench/CAIL2018, AgentsBench mostró un rendimiento superior frente a los métodos tradicionales. El marco, al usar GPT-4, alcanzó un rendimiento del 86.33% (medido por nLog-distance), notablemente superior al 80.28% obtenido por el método Legal Syllogism (LS). Además, obtuvo una puntuación sobresaliente en la evaluación cualitativa de Moralidad (76.2% con GPT-4). **[Conclusiones]** Los resultados demuestran que AgentsBench no solo aumenta la precisión de LJP, sino que también mejora la equidad y las consideraciones éticas en la toma de decisiones legales mediante la simulación de la deliberación multi-agente. El marco es extensible a otros escenarios legales que requieran procesos de decisión colectiva.

2. **[Tipo de Documento]:** Artículo **[Título]:** Chatlaw: A Multi-Agent Collaborative Legal Assistant with Knowledge Graph Enhanced Mixture-of-Experts Large Language Model [4]

[Problemática] La limitada disponibilidad de profesionales y el alto costo de los servicios legales restringen el acceso a la justicia, problemática crítica evidenciada en China, donde los centros de asistencia legal procesan anualmente solo una cuarta parte de los 700,000 casos recibidos. Si bien los asistentes basados en modelos de lenguaje grande (LLMs) ofrecen soluciones, estos presentan el riesgo inherente de la alucinación, produciendo información que puede ser engañosa, incompleta o desactualizada, lo cual genera potenciales riesgos legales. **[Solución]** Para abordar estos desafíos y mejorar la fiabilidad, se diseñó Chatlaw, un asistente legal virtual que utiliza un modelo Mixture-of-Experts (MoE) entrenado con un dataset legal de alta calidad mejorado con grafos de conocimiento. Este modelo está integrado con un sistema de múltiples agentes que básicamente imita cómo funcionan los bufetes de abogados en la vida real, usando lo que se llama Procedimientos Operativos Estándar (SOP). Lo que hace es delegar diferentes tareas a distintos roles, como por ejemplo un Asistente Legal o un Abogado Senior.

[Resultados] Chatlaw-MoE mostró que funciona muy bien. De hecho, superó a GPT-4 en la evaluación de Lawbench, donde sacó un puntaje promedio de 60.08 mientras que GPT-4 obtuvo 52.35, lo cual significa una mejora del 7.73% en precisión. Además de eso, consiguió 11 puntos más que GPT-4 en el promedio del Examen de Calificación Unificada para Profesionales Legales: 115 puntos contra 104. **[Conclusiones]** Los resultados muestran que el sistema realmente tiene una buena capacidad para responder consultas legales. Destaca especialmente en qué tan completas son sus respuestas, en cómo orienta al usuario y en la autoridad que tienen sus respuestas. Pero los autores también reconocen que hay cosas que mejorar: necesitan trabajar más en proteger la privacidad y reducir la cantidad enorme de recursos computacionales que requiere el sistema. Para esto último, mencionan que podrían aplicar técnicas de compresión de modelos.

3. **[Tipo de Documento]:** Artículo **[Título]:** LegalAgentBench: Evaluating LLM Agents in Legal Domain [19]

Los agentes de lenguaje avanzado tienen bastante potencial en el área legal, pero se enfrentan a una **[Problemática]** importante: las evaluaciones que existen actualmente no logran capturar realmente qué tan compleja es la toma de decisiones en el ámbito judicial. Lo que pasa es que los desafíos legales necesitan un razonamiento que tiene varios niveles y también requieren conocimiento muy especializado. Pero los conjuntos de datos que hay disponibles solo se enfocan en tareas básicas y no abordan análisis más profundos de casos ni tampoco procesos judiciales que sean realmente complejos. **[Solución]** Para intentar solucionar esta limitación, lo que hicieron fue crear LegalAgentBench, que es un sistema de evaluación especializado en el contexto legal de China. Este sistema incorpora 17 bases de datos especializadas y 37 herramientas para hacer consultas externas, lo cual permite que los agentes puedan coordinar todos estos recursos para resolver problemas jurídicos. Usando un método que se puede escalar, desarrollaron 300 tareas que están clasificadas de forma detallada e incluyen razonamiento complejo y también redacción jurídica. **[Resultados]** Cuando evaluaron ocho modelos de lenguaje usando métodos como Plan-and-Solve y ReAct, el que mejor funcionó fue GPT-4o, que logró un 79.08% de efectividad. Sin embargo, el rendimiento bajaba bastante cuando las tareas eran más complejas: en preguntas de un solo nivel alcanzaba el 93%, pero en preguntas de cinco niveles bajaba hasta apenas el 61%. **[Conclusiones]** LegalAgentBench logra mostrar de manera

efectiva las diferencias que hay entre los distintos modelos. Lo que revela es que los agentes todavía necesitan mejorar mucho, especialmente en cosas como el conocimiento legal especializado y la comprensión de normativas y precedentes, que son elementos básicos y necesarios para tener la precisión que se necesita en aplicaciones del mundo jurídico.

4. **[Tipo de Documento]:** Artículo **[Título]:** Integrating AI-Based Information Services in Legal Systems: Opportunities and Challenges [20]

La Inteligencia Artificial se ha estado incorporando cada vez más en el mundo legal, usando herramientas como software para contratos y asistentes virtuales. **[Problemática]** Esto ha hecho que muchas tareas sean más rápidas y ha mejorado bastante la eficiencia, la precisión y el acceso a servicios legales. Pero su uso también trae problemas éticos y operativos que son bastante serios, especialmente en temas como la privacidad de los datos, los sesgos que pueden tener los algoritmos, y quién es responsable cuando algo sale mal. Un problema central que expone esta investigación es que no hay marcos regulatorios completos, entonces queda en un vacío legal el tema de a quién se le atribuye la culpa cuando los sistemas de IA toman decisiones autónomas o cuando se vulnera la confidencialidad de la información. **[Solución]** Lo que hace esta investigación es analizar las políticas que regulan cómo se implementan estas tecnologías de IA. Para esto usaron una metodología mixta que combina varias cosas: estudiaron casos concretos, hicieron encuestas estructuradas y realizaron entrevistas con personas clave del sector. El análisis se enfoca en el uso de machine learning, procesamiento de lenguaje natural y análisis predictivo. **[Resultados]** Cuando se implementa IA en el sector legal, lo que pasa es que se hace más rápida la investigación y el análisis de documentos complejos, lo cual optimiza cómo se evalúan los casos y se toman decisiones. La tecnología también permite detectar de forma automática errores e inconsistencias cuando se están elaborando documentos, y esto reduce de manera significativa el tiempo que se necesita y también disminuye los errores que normalmente cometen las personas. **[Conclusiones]** Aunque la IA tiene potencial para reducir la carga de trabajo y mejorar tanto la precisión como la accesibilidad de los servicios legales, se concluye que es urgente crear regulaciones y marcos legales específicos para esto. Esto es indispensable si se quiere asegurar que los sistemas sean transparentes, equitativos y que haya responsabilidad clara. Al mismo tiempo, hay que proteger la justicia y mantener la confianza que tiene la gente en el sistema.

5. **[Tipo de Documento]:** Artículo **[Título]:** LegalBot-EC: An LLM-Based Chatbot for Legal Assistance in Ecuadorian Law [5]

[Problemática] En Ecuador, el sistema legal tiene un problema grande. Hay demasiadas normas y el lenguaje que usan es súper técnico. Esto hace que sea difícil para la gente común entenderlo. Pero no solo eso, hasta los mismos abogados tienen problemas cuando necesitan consultar ciertos textos. Por eso nació la idea de crear LegalBot-EC, una herramienta que ayuda con temas legales de forma automática. **[Solución]** El sistema usa algo llamado RAG (Generación Aumentada por Recuperación). Básicamente combina dos cosas: buscar información de forma inteligente y generar texto. Para hacerlo funcionar utilizaron el modelo LLaMA 3.1 en su versión de 8B como cerebro principal. También metieron ChromaDB para guardar y buscar información en formato vectorial. Y como el español tiene sus particularidades, agregaron BETO, que es un modelo entrenado específicamente para nuestro idioma y ayuda a entender mejor las preguntas. Lo interesante es que solo le dieron dos fuentes de información: el COIP y la Constitución de 2008. Nada más. Así garantizan que todo lo que responde está basado en las leyes ecuatorianas actuales. **[Resultados]** Para la demostración, hicieron pruebas con estudiantes de Derecho. Les pidieron que lo usaran y después que lo calificaran. Los números fueron buenos. La satisfacción promedio fue de 88.72 sobre 100. En cuanto a qué tan preciso es, le hicieron 25 preguntas legales. Respondió bien 23, y en 2 la respuesta fue parcialmente correcta. Eso da una precisión del 96%. **[Conclusiones]** Según los resultados, LegalBot-EC funciona bien para dar ayuda jurídica básica en Ecuador. Hasta puede entender algunas preguntas en inglés básico, aunque no es su fuerte. Pero tiene sus límites. Solo conoce dos documentos legales, entonces no puede ayudar con otras áreas del derecho. También hay que mencionar que la forma en que midieron la precisión podría tener algo de subjetividad porque fue basada en el consenso de los autores. Para mejorar esto en el futuro, deberían agregar más documentos legales y usar formas más objetivas de medir qué tan bien funciona.

6. **[Tipo de Documento]:** Artículo **[Título]:** CHRExpert: An AI-Driven Court of Human Rights Expert Assistant for Legal Practitioners Utilizing Transformer Models [21]

[Problemática] Los abogados que se dedican a defender derechos humanos la tienen complicada. Es una de las áreas más difíciles del derecho. ¿Por qué? En primer lugar: porque las

leyes cambian todo el tiempo. Tienes que estar actualizándote constantemente. Y como las leyes cambian tanto, es difícil planear los casos porque no sabes si van a modificar algo justo cuando estás trabajando. Pero eso no es todo. También tienen que revisar montones de documentos. Jurisprudencia, informes de organizaciones, tratados internacionales. Es mucho material. Esto les consume un montón de tiempo y recursos. Además, las herramientas de inteligencia artificial que hay ahora no ayudan mucho, ya que les cuesta bastante entender los matices del contexto y la discrecionalidad de los jueces, que son cosas cruciales en este tipo de litigios. **[Solución]** Para solucionar este problema, desarrollaron CHRExpert, que es un asistente legal basado en IA. Básicamente, es un modelo de lenguaje avanzado (un GPT con 6 mil millones de parámetros) que entrenaron específicamente con todos los casos del Tribunal Europeo de Derechos Humanos (TEDH). Lo que hace CHRExpert es automatizar el análisis de los casos: interpreta la normativa y usa razonamiento por analogía para proponer las mejores estrategias legales. **[Resultados]** Cuando lo probaron evaluando su desempeño con sentencias definitivas, los resultados fueron bastante prometedores. Logró una precisión del 83% al predecir el resultado de casos relacionados con los Artículos 3, 6 y 8 del Convenio Europeo de Derechos Humanos, con una puntuación AUC media de 0.93. Además, redujo el tiempo que se necesita para preparar casos en un 40% y demostró una precisión del 92% cuando tiene que identificar los asuntos legales más importantes dentro de un caso. **[Conclusiones]** Si bien CHRExpert demuestra que la IA tiene un gran potencial para optimizar el trabajo legal y ofrecer nuevas perspectivas, no es perfecto. Detectamos algunas limitaciones importantes: al sistema todavía le cuesta manejar la discrecionalidad de los jueces y las leyes ambiguas. Además, somos conscientes de que el propio conjunto de datos del TEDH podría tener un sesgo de selección, lo que podría afectar el rendimiento del modelo.

7. **[Tipo de Documento]:** Artículo **[Título]:** Claude Rules: An Evaluation of Large Language Models' Applicability to Solve Cases in German Business Law [22]

Las inteligencias artificiales conversacionales como Claude 3 están cambiando el mundo de la información legal. Son herramientas que podrían revolucionar cómo trabajamos con leyes. **[Problemática]** ChatGPT-4 había sacado notas excelentes en el examen de abogacía de Estados Unidos. Se ubicó en el percentil más alto. Pero había una duda importante: ¿funcionaría igual de bien con otros idiomas y sistemas legales? Por ejemplo, con el derecho alemán. Nadie estaba

seguro. [Solución] Tres investigadores (Sascha Schweitzer, Markus Conrads y Jörg Naeve) decidieron averiguarlo. Armaron un examen con 200 preguntas sobre derecho alemán. Todas únicas. Después hicieron 1,600 evaluaciones automáticas en formato multiple choice. Querían que fuera lo más objetivo posible. Probaron cuatro modelos: Claude 3 (Opus), Google Gemini, ChatGPT-4 y ChatGPT-3.5. [Resultados] Claude 3 ganó por lejos. Respondió correctamente el 60% de las preguntas sobre derecho mercantil. ChatGPT-4 solo llegó al 49%. Es más, Claude 3 fue el único que pasó el 50% necesario para aprobar. En todas las áreas que probaron del derecho alemán, Claude 3 fue mejor. [Conclusiones] Aunque Claude 3 demostró ser superior, los investigadores hicieron una advertencia clara. Esta IA, igual que las otras, tiene limitaciones importantes. Y lo peor es que esas limitaciones pueden ser difíciles de detectar si no eres experto. Por eso la recomendación final es tajante: los abogados tienen que verificar siempre, de forma exhaustiva, cualquier cosa que genere una IA antes de usarla profesionalmente. No pueden confiar ciegamente.

8. **[Tipo de Documento]:** Artículo **[Título]:** A Knowledge Base of Argumentation Schemes for Multi-Agent Systems [23]

[Problemática] Argumentar es algo que los humanos hacemos muy bien. Es parte de nuestra inteligencia. Si queremos crear IAs realmente útiles, tienen que poder hacer lo mismo. En sistemas donde hay varios agentes de IA trabajando juntos (se llaman MAS), el desafío es grande. Estos agentes no solo tienen que pensar y hablar entre ellos. Tienen que poder explicarnos a nosotros, los humanos, por qué tomaron tal o cual decisión. Es crucial para que podamos confiar en ellos. Aquí es donde entran los "esquemas de argumentación" (AS por sus siglas en inglés). Son como la herramienta fundamental que les permite a las IAs debatir y justificar sus acciones. Sin esto, no hay forma de que una IA nos explique su razonamiento de manera que tenga sentido para nosotros. **[Solución]** Para abordar este desafío, Ferreira y su equipo (2024) proponen crear una "Base de Conocimiento" (KB) que esté llena de estos esquemas de argumentación. La idea es que esta base de datos le dé a los agentes la capacidad de argumentar tanto en situaciones generales como en campos muy específicos. La implementaron usando la sintaxis de Jason, que es un lenguaje para agentes inteligentes, y lo clave de su método fue diseñar plantillas de lenguaje natural para cada esquema. De esta manera, los argumentos lógicos de la máquina se traducen automáticamente en explicaciones que cualquier persona

puede entender. **[Resultados]** Hasta ahora, esta base de conocimiento contiene 73 esquemas de argumentación diferentes, organizados por temas: 22 esquemas generales basados en el trabajo del experto Douglas Walton, 40 esquemas especializados para un caso de uso sobre asignación de camas en hospitales y 11 esquemas diseñados para el razonamiento en casos legales. Para demostrar que su enfoque funciona, lo aplicaron a un escenario del ámbito legal. En la prueba, un agente utilizó los esquemas para deducir la posible intención detrás de un crimen y fue capaz de explicar claramente cómo llegó a esa conclusión. **[Conclusiones]** Los investigadores concluyen que implementar esta base de conocimiento y usar plantillas para generar explicaciones en lenguaje claro y sencillo aporta una gran transparencia al razonamiento de los sistemas de IA. Esta herramienta es fundamental para probar qué tan bien funciona el sistema en diferentes áreas, permitiendo que los usuarios sigan el "hilo" del pensamiento de la IA de una forma lógica y precisa.

9. **[Tipo de Documento]:** Artículo **[Título]:** An Intelligent Conversational Agent for the Legal Domain [24]

[Problemática] El derecho siempre ha sido un campo difícil para la inteligencia artificial, principalmente porque las leyes son flexibles, las interpretaciones de los jueces varían y los desarrolladores se enfrentan a mucha incertidumbre. En este contexto, la investigación se enfocó en crear CREA2, un asistente conversacional diseñado para ayudar a residentes de la Unión Europea con disputas sobre activos, como divorcios, herencias o la división de una empresa. El principal obstáculo técnico fue la escasez de datos; con un archivo de poco más de 300 preguntas y respuestas legales, era imposible usar técnicas que dependen de grandes volúmenes de información, como la clasificación de intenciones. **[Solución]** Para superar esta limitación, el equipo optó por un enfoque basado en recuperar preguntas similares usando el modelo Sentence-BERT (SBERT), que es muy bueno para entender el significado semántico de las oraciones. Adicionalmente, utilizaron una herramienta llamada Parrot para aumentar su conjunto de datos mediante parafraseo, logrando multiplicar la información de entrenamiento 4.22 veces. **[Resultados]** Al medir el rendimiento con el F1-score y la precisión, el modelo ajustado llamado quora-distilbert-multilingual demostró ser el más eficaz, alcanzando un F1-score final de 0.89 (mejorando desde un 0.70 inicial) y una precisión del 82% al clasificar correctamente la intención del usuario. Este resultado superó al otro modelo probado, all-mpnet-base-v2.

[Conclusiones] Los autores concluyen que el sistema basado en SBERT es una base sólida y efectiva para un asistente conversacional en el ámbito legal, especialmente cuando se cuenta con pocos datos. Sin embargo, reconocieron que es necesario investigar si el sistema puede generalizarse para cubrir una gama más amplia de temas legales, ya que por ahora su aplicación se limita a un conjunto muy específico de disputas.

10. **[Tipo de Documento]:** Artículo **[Título]:** Designing normative theories for ethical and legal reasoning: LogiKeyframework, methodology, and tool support [25]

[Problemática] Traducir teorías éticas y legales a un lenguaje lógico es fundamental, pero choca con la complejidad de conceptos como las "obligaciones contrarias al deber" (CTD), que describen qué hacer cuando una norma ya ha sido violada. Se ha comprobado que las lógicas tradicionales que se usan para este tipo de razonamiento, como la Lógica Deónica Estándar (SDL), fallan en estos casos y se vuelven inconsistentes hasta el punto de "romperse". **[Solución]** Para superar esto, desarrollaron el marco LogiKey, que usa una lógica de orden superior (HOL) como si fuera una especie de "traductor universal" muy expresivo. Mediante una técnica conocida como 'incrustación semántica', LogiKey tiene la capacidad de aprender, representar y codificar las reglas de diversas lógicas deónicas, como los sistemas creados por Åqvist y Carmo & Jones. Por lo tanto. En lugar de inventar todo de nuevo, el sistema se conecta con herramientas de razonamiento muy potentes que ya existen, como Isabelle/HOL y Leo-III. **[Resultados]** Para comprobar su eficacia, los investigadores pusieron a prueba LogiKey en distintos casos prácticos. Cuando formalizaron la regulación GDPR de la UE en un escenario donde se violan normas, la lógica estándar (SDL) falló, confirmando que es inconsistente. Pero la implementación de LogiKey manejó la situación sin ningún problema, razonando correctamente sobre las nuevas obligaciones sin volverse inconsistente. Además, el marco demostró su potencia cuando logró mecanizar y verificar una teoría ética muy compleja (el Principio de Consistencia Genérica de Gewirth), probando que puede escalar. **[Conclusiones]** Los experimentos muestran que LogiKey es una infraestructura robusta, flexible y escalable para estudiar teorías ético-legales de forma práctica. Aunque la lógica HOL que usa es teóricamente indecidible, los autores señalan que esto no es un problema real, ya que al reutilizar la tecnología de razonamiento automatizado que ya existe, se logran hacer experimentos eficientes y confiables.

11. **[Tipo de Documento]:** Artículo **[Título]:** Legal Judgment Prediction Based on Multiclass Information Fusion [26]

[Problemática] La Predicción de Sentencias Judiciales (LJP, por sus siglas en inglés) es una herramienta importante en los sistemas que ayudan con temas legales. Su objetivo es anticipar cuál va a ser el resultado de un juicio basándose en los hechos del caso. Pero la mayoría de los modelos que hay ahora tienen dos problemas grandes. Primero, trabajan con información incompleta porque ignoran datos externos que los jueces sí toman en cuenta, como los antecedentes del acusado o las opiniones previas del tribunal. Segundo, les cuesta procesar documentos legales largos, lo que hace que se pierdan detalles importantes o conexiones clave a lo largo del texto. **[Solución]** Para resolver estas limitaciones, Kongfan Zhu et al. proponen la Transformer-Hierarchical-Attention-Multi-Extra (THME) Network. Para resolver estos problemas, la arquitectura que diseñaron está hecha para aprovechar toda la información que está disponible. Por un lado, usa un Codificador de Datos Estructurados que procesa datos externos clave, tanto los numéricos como los categóricos. Al mismo tiempo, emplea un codificador especial llamado Red de Atención Jerárquica Transformer (TH), diseñado específicamente para analizar los largos textos de los hechos, captando las conexiones importantes a lo largo del documento y entendiendo el significado correcto de las palabras según su contexto. Finalmente, ambos tipos de información se integran en un clasificador que imita la estructura lógica del razonamiento judicial: primero analiza las leyes aplicables, luego determina los cargos y, finalmente, predice la pena. **[Resultados]** Los experimentos se realizaron en CJO, un conjunto de datos a gran escala de 750,000 documentos de casos penales en el sistema de derecho civil. THME demostró ser superior a los modelos de referencia en todas las tareas de predicción de juicios, alcanzando una precisión del 96.36% y un Macro-F1 del 81.77% en la predicción de cargos. Un estudio de ablación demostró que los datos estructurados mejoraron la predicción de los términos de la pena en un 2.51% en comparación con el modelo de tarea única sin datos estructurados. **[Conclusiones]** El estudio concluye que el uso de información basada en la determinación de hechos, extraída mediante el Structured Data Encoder, mejora efectivamente la predicción de juicios, particularmente la predicción de la pena. Sin embargo, la predicción de los términos de la pena sigue siendo una limitación crítica, con un Macro-F1 de solo 45.71% para

THME, un rendimiento aún deficiente atribuido principalmente al severo desequilibrio de categorías en los datos.

1.1.6. Tabla comparativa

A continuación se muestra la tabla comparativa entre los antecedentes de los documentos de investigación encontrados.

Cita	Tecnologías / Modelos	Metodologías	Métricas de Evaluación	Limitaciones
[1]	LLMs (GPT-4), simulación multi-agente	Role-playing, deliberación colegiada	nLog-distance, evaluación cualitativa de moralidad	Alto costo computacional, dependencia de GPT-4
[2]	MoE LLM con grafos de conocimiento	SOP multi-agente, delegación de roles	LawBench, Examen Nacional de Profesionales Legales	Riesgo de alucinación, alta demanda computacional, privacidad
[3]	Benchmarks para LLMs legales, herramientas externas	Plan-and-Solve, Plan-and-Execute, ReAct	Tasa de Éxito, Tasa de Progreso	Bajo rendimiento en razonamiento complejo (multi-hop), falta de conocimiento legal especializado

[4]	ML, NLP, analítica predictiva	Métodos mixtos (casos, encuestas, entrevistas)	No aplica	Carencia de marcos regulatorios y gobernanza
[5]	RAG (LLaMA 3.1), BETO, ChromaDB	Recuperación semántica con embeddings	Precisión ponderada (96%), satisfacción usuario (88.7/100)	Base de conocimiento limitada (solo COIP y Constitución 2008), sesgo en evaluación
[6]	Transformer GPT (6B), fine-tuning en ECHR	Interpretación estatutaria, razonamiento analógico	Precisión (83%), AUC (0.93), reducción de tiempo (40%)	Discreción judicial difícil de modelar, sesgo en dataset
[7]	Claude 3, ChatGPT, Gemini	Evaluación cuantitativa (1600 pruebas)	Exactitud (60% Claude, 49% GPT-4)	Inseguridad sobre fiabilidad, necesidad de validación profesional
[8]	MAS, Jason, esquemas de Walton	Modelado de AS + plantillas de lenguaje natural	Validación en casos legales (explicabilidad)	Escenarios aún limitados, cobertura parcial de dominios
[9]	SBERT, Parrot (data augmentation)	Recuperación de intenciones,	F1 (0.89), Precisión (0.82)	Corpus muy reducido,

		embeddings semánticos		generalización limitada
[10]	HOL (Isabelle/HOL, Leo-III), SSE	Formalización de lógicas deónticas	Model checking (Nitpick), consistencia lógica	Complejidad teórica (indecidibilidad de HOL)
[11]	Transformer + Hierarchical Attention + Structured Data Encoder	Multiclass fusion, clasificación topológica	Precisión (96.36%), Macro-F1 (81.77%), ablation study	Bajo Macro-F1 en predicción de pena (45.71%), desequilibrio de clases

Adicionalmente, se realizó un análisis técnico y funcional de herramientas comerciales disponibles en el mercado, tomando como referencia la solución *Juztina*. Los hallazgos, detallados en la Tabla 2, evidencian carencias críticas para su aplicación en el contexto de la defensa pública masiva.

Tabla 2

Análisis de limitaciones técnicas y funcionales de la herramienta Juztina

Categoría	Descripción de la Limitación Detectada
Input (Formatos)	Restricción a archivos PDF y Word (máx. 4.5 MB). Incompatibilidad con formatos multimedia (audio/video) e imágenes.
Conectividad	Ausencia de acceso a internet en tiempo real; limitación a base de datos estática interna ("caja cerrada").
Veracidad	Falta de validación fáctica; propensión a aceptar premisas falsas o

	leyes inexistentes propuestas por el usuario.
Procesamiento	Latencia alta en respuestas y calidad de OCR deficiente en documentos escaneados de baja resolución.
Razonamiento	Ausencia de cadena de pensamiento (<i>Chain of Thought</i>) visible; opera como "caja negra" sin trazabilidad lógica.
Costo	Modelo de cobro por consulta individual, desincentivando la iteración y el refinamiento de búsquedas legales complejas.

Asimismo, se evaluó la herramienta Lexius.AI, un asistente legal entrenado específicamente en el contexto normativo peruano. Aunque esta solución presenta avances notables, como la incorporación de Inteligencia Artificial Explicable (XAI) y el uso de arquitecturas RAG para fundamentar sus respuestas, se identificaron limitaciones operativas y de seguridad críticas. En su modalidad de acceso gratuito, la herramienta restringe funcionalidades esenciales como la carga y análisis de documentos (PDF), limitando su interacción a un chat convencional. De mayor gravedad es su vulnerabilidad ante técnicas de prompt injection: las pruebas evidenciaron una propensión a validar premisas falsas o normativas inexistentes inducidas por el usuario, lo que compromete la veracidad de la asistencia y evidencia la falta de filtros de validación fáctica robustos.

1.1.7. Discusión

El análisis muestra una fuerte dependencia de LLMs y arquitecturas Transformer, aplicados con distintos enfoques. AgentsBench [1] y Chatlaw [2] destacan por sus marcos multi-agente: alcanzaron un 86.33% en nLog-distance y una mejora del 7.73% en Lawbench frente a GPT-4, respectivamente. En contraste, LegalAgentBench [3] evidenció la debilidad del razonamiento complejo, donde el rendimiento cayó del 93% en precisión de tareas al 61% en cinco saltos.

En soluciones específicas, LegalBot-EC [5] logró 96% de precisión y 88.7% en satisfacción de usuarios, pero su conocimiento se limita al COIP y la Constitución ecuatoriana. CHRExpert [6] alcanzó AUC 0.93 y redujo el tiempo de preparación en 40%, aunque sigue sin manejar bien la

discrecionalidad judicial. Claude Rules [7] mostró que Claude 3 alcanzó un 60% de exactitud en derecho mercantil alemán, superando a GPT-4 (49%), pero con dudas sobre fiabilidad.

Otros aportes refuerzan la explicabilidad y formalización normativa: la KB(Base de Conocimiento) [8] de esquemas de argumentación ofrece 73 plantillas para trazabilidad de decisiones, mientras que LogiKEy [10] formalizó la GDPR(Regulación General de Protección de Datos) resolviendo inconsistencias que la SDL(Lógica Deónica Estándar) no pudo manejar. Finalmente, el modelo THME Network [11] alcanzó 96.36% de precisión en predicción de cargos, pero solo 45.71% en predicción de penas, reflejando el impacto del desbalance de datos.

Las limitaciones comunes son: alto costo computacional [1], [2], bases de conocimiento restringidas [5], sesgos y desbalance de datos [6], [11] y la falta de marcos regulatorios claros [4], [10]. Como también se pudo observar que de los 11 documentos revisados solo 1 es de sudamérica: LegalBot-EC [5], los demás son de otros continentes, por ende hay una limitación en cuanto al contexto y alcance a sistemas jurídicos de cada país, en particular Perú de sudamérica.

Adicionalmente, al contrastar los avances académicos con la oferta tecnológica disponible en el mercado legal peruano, se analizaron herramientas como Juztina y Lexius.AI. Si bien esta última incorpora tecnologías prometedoras como la Inteligencia Artificial Explicable (XAI) y arquitecturas RAG contextualizadas a la normativa nacional, el análisis técnico reveló vulnerabilidades críticas en ambas soluciones. Se evidenció una marcada propensión a fallos de seguridad como el prompt injection, donde modelos como Lexius.AI validaron normativas inexistentes sugeridas por el usuario, comprometiendo la veracidad jurídica. A esto se suman barreras de accesibilidad en sus versiones gratuitas, como la imposibilidad de procesar expedientes en PDF o la falta de conexión a internet en tiempo real en el caso de Juztina. Estas carencias demuestran que, aunque existen iniciativas locales, estas aún operan como 'cajas negras' o carecen de los filtros de validación fáctica necesarios para ser herramientas confiables en la defensa pública masiva.

1.1.8. Conclusiones

La revisión sistemática de la literatura y el análisis de las herramientas existentes permiten concluir que, si bien la inteligencia artificial legal ha logrado superar a métodos tradicionales en

tareas específicas, persisten limitaciones estructurales y técnicas cuantificables que impiden su adopción segura en el sistema de justicia peruano:

Limitaciones en la Investigación Académica: A pesar de la alta precisión en tareas simples, los modelos actuales evidencian una deficiencia crítica en el razonamiento complejo. Estudios como el de LegalAgentBench demuestran una caída drástica en el rendimiento, descendiendo del 93% de éxito en consultas de un solo nivel a apenas un 61% en tareas que requieren cinco saltos deductivos. Asimismo, el desbalance de datos sigue afectando la equidad del sistema; modelos como THME Network, aunque precisos en la predicción de cargos (96.36%), mostraron un desempeño deficiente en la predicción de penas, con un puntaje Macro-F1 de solo 45.71%. A esto se suma la restricción de dominio, donde soluciones efectivas como LegalBot-EC limitan su base de conocimiento a solo dos cuerpos normativos (COIP y Constitución), restringiendo su generalización ,.

Limitaciones en Herramientas Locales (Juztina y Lexius.AI): El análisis de soluciones comerciales reveló barreras técnicas tangibles. En el caso de Juztina, la capacidad de análisis de contexto se ve severamente restringida por un límite de carga de archivos de 4.5 MB y la incompatibilidad con formatos multimedia. Por su parte, Lexius.AI, en su capa de acceso libre, impide totalmente la ingesta de documentos PDF, limitando la interacción a un chat sin contexto documental. Ambas herramientas mostraron vulnerabilidad crítica ante prompt injection, validando premisas falsas inducidas por el usuario sin contraste fáctico, lo cual, sumado a la falta de transparencia (caja negra), compromete la seguridad jurídica necesaria para la defensa pública.

En consecuencia, se confirma la necesidad de desarrollar una solución que no solo integre arquitecturas RAG y multiagente para mitigar la caída de rendimiento en razonamientos complejos, sino que implemente filtros de seguridad robustos y soporte multimedia, superando las restricciones técnicas observadas en la oferta actual.

1.2. Fundamentos teóricos

En esta sección se definen los conceptos tanto de dominio, tecnología y metodología que corresponden a el estado del arte del tema seleccionado a desarrollar.

[Teoría de Dominio]

a. Derecho Penal (Objetivo y Subjetivo) [27]

El derecho penal se define como el conjunto de normas jurídicas que describen ciertas conductas como delitos o faltas y establecen la imposición de penas o medidas de seguridad. Constituye la herramienta de control social más enérgica del Estado, y su uso se recomienda como último recurso (última ratio legis), aplicándose sólo cuando otros medios de control social resultan insuficientes. Se manifiesta de dos formas:

- Derecho Penal Objetivo (ius poenale): Es el conjunto de normas jurídico-penales que se refieren al delito, al sujeto responsable y a sus consecuencias (penas y medidas de seguridad).
- Derecho Penal Subjetivo (ius puniendi): Se refiere a la potestad exclusiva y excluyente que la sociedad delega en el Estado para definir qué conductas constituyen un delito e imponer las sanciones correspondientes a quienes infringen la ley. Básicamente, este es el fundamento por el cual los ciudadanos renuncian a hacer justicia por su propia mano y le ceden al Estado el monopolio del uso legítimo de la fuerza para mantener el orden social. Este poder no es absoluto ni arbitrario. Al contrario, está delimitado de forma rigurosa por la propia norma penal, que es la expresión formal de las decisiones que toma la comunidad sobre qué conductas deben ser castigadas y de qué manera, canalizando así la respuesta frente al crimen a través de un sistema institucional y predecible.

b. Principio de Legalidad [27]

Este principio es uno de los pilares de nuestra libertad, porque actúa como un escudo que protege a cada ciudadano frente al enorme poder del Estado, poniéndole un límite claro a su capacidad de castigar. Toda la idea se resume en una máxima fundamental: *nullum crimen, nulla poena sine lege*, que en español claro significa que no puede haber delito ni castigo si no existe una ley previa que así lo establezca. En la legislación peruana, esto se aplica de manera estricta: nadie puede ser llevado a juicio ni sentenciado por una acción que, en el momento en que se realizó, no estaba ya definida por la ley, de forma expresa y sin ambigüedades, como un delito. De la misma manera, la sanción que se imponga debe ser exactamente la que esa misma ley ya tenía

contemplada, garantizando así que las reglas del juego son conocidas por todos y que nadie será castigado por una falta inventada sobre la marcha. Este principio implica cuatro garantías:

- Ley cierta (*lex certa*): La ley penal debe ser redactada con la mayor precisión posible.
- Ley previa (*lex previa*): Se prohíbe la aplicación retroactiva de la ley penal en perjuicio del reo.
- Ley escrita (*lex scripta*): Se rechaza la costumbre como fuente de delitos o penas.
- Ley estricta (*lex stricta*): Se prohíbe la aplicación de la ley penal por analogía para sancionar una conducta.

c. Principio de Lesividad [27]

El principio de lesividad exige que, para que el derecho penal intervenga, un bien jurídico tutelado debe ser lesionado o puesto en peligro. Pensemos en estos "bienes jurídicos" como los pilares que sostienen nuestra convivencia: la vida, la salud, la libertad o la propiedad. Son los tesoros que, como comunidad, hemos decidido proteger por encima de todo, y por eso los elevamos a un nivel constitucional.

Este principio es crucial en el sistema peruano porque actúa como un freno a la arbitrariedad del Estado. En la práctica, asegura que el inmenso poder de castigar solo se use cuando sea estrictamente necesario, es decir, cuando se ha herido de verdad uno de estos valores esenciales, y no para sancionar conductas que, aunque puedan ser mal vistas, no le hacen daño tangible a nadie.

d. Principio de Culpabilidad [27]

Este principio, fundamental para una justicia equitativa, establece que la responsabilidad penal es estrictamente personal. En esencia, nos dice que una persona solo puede ser juzgada y sancionada por sus propias acciones, y nunca por el simple resultado de un hecho si no hubo intención o negligencia de su parte. Queda así prohibido castigar a alguien por lo que hizo un tercero o por consecuencias que eran genuinamente imprevisibles. Para que el Estado pueda imponer una pena, no basta con que haya ocurrido un daño; es indispensable demostrar que esa acción puede serle reprochada directamente al acusado. Es aquí donde conceptos como el dolo (la intención de dañar) y la culpa (la imprudencia) se vuelven cruciales, pues son la

manifestación de que la persona tuvo un control voluntario sobre el acto, haciendo que la sanción sea justa y merecida.

e. Teoría del Delito (Estructura Tripartita) [27]

El delito se define comúnmente como una acción que está tipificada, es contraria al derecho y es imputable a su autor. Esta definición contiene todos los caracteres necesarios para que una conducta sea considerada un delito. Estos tres elementos constituyen niveles de imputación ordenados sistemáticamente. Primero, se analiza la tipicidad, que es la adecuación de la conducta a la descripción legal de un delito. Segundo, se evalúa la antijuridicidad, que confirma que dicha conducta es contraria al ordenamiento jurídico en su conjunto. La conducta que cumple con estos dos primeros niveles se denomina "injusto". Finalmente, para que exista responsabilidad penal, se debe determinar la culpabilidad, que es la imputación personal del hecho al autor.

f. Tipicidad [27]

La tipicidad es el proceso técnico mediante el cual un hecho ocurrido en la realidad es subsumido en la descripción hipotética de una conducta prohibida, la cual es creada por el legislador y se denomina tipo penal. El tipo penal es, por tanto, la descripción de la conducta en la ley, mientras que la tipicidad es la adecuación de un hecho concreto a ese tipo. Este proceso, llamado juicio de tipicidad, es una operación de imputación que se realiza tomando como base el bien jurídico que la norma busca proteger. La función más relevante del tipo penal es la indiciaria, ya que la tipicidad de una conducta es un indicio de su antijuridicidad.

g. Dolo y Culpa (Imputación Subjetiva) [27]

Estos conceptos forman parte de la imputación subjetiva y se refieren al aspecto interno o mental del autor al cometer el hecho.

- Dolo: Es el conocimiento y la voluntad de realizar todos los elementos del tipo objetivo. Aunque la ley peruana no lo define explícitamente, la doctrina acepta que posee un elemento cognitivo (saber lo que se hace) y un elemento volitivo (querer hacerlo).
- Culpa (o Imprudencia): La responsabilidad penal por imprudencia surge sólo cuando se incumple un deber básico de cuidado y esa falta provoca directamente un daño tipificado como

delito. A diferencia del dolo, en la imprudencia no existe intención de causar el resultado, sino que este ocurre por descuido. Esta distinción es fundamental en el derecho penal, ya que influye tanto en la calificación del delito como en la severidad de la sanción, siendo la imprudencia generalmente menos castigada por carecer de voluntad dañosa.

h. Sistema Peruano de Información Jurídica (SPIJ) [28]

El SPIJ es la plataforma oficial del Ministerio de Justicia de Perú [28]. Su trabajo es organizar todas las leyes del país y ponerlas disponibles para el público. Básicamente reúne, ordena y actualiza todo el marco normativo nacional. También crea conexiones entre normas relacionadas para que sea más fácil entenderlas.

Pero no es solo un archivo digital de leyes. Tiene herramientas de búsqueda rápidas y precisas que ayudan tanto a abogados como a ciudadanos comunes a encontrar lo que necesitan. La idea va más allá de solo informar. Busca darle poder a la gente para que pueda defender sus derechos y cumplir con sus obligaciones.

Además, el SPIJ no solo tiene leyes. También incluye jurisprudencia relevante, análisis de expertos y tratados internacionales. Todo esto ayuda a que el sistema judicial peruano sea más transparente y eficiente.

[Teoría de Tecnología]

a. Machine Learning [29]

El machine learning es una parte de la inteligencia artificial que se dedica a crear sistemas que aprenden solos de los datos. No es como los programas normales que siguen instrucciones fijas. Estos sistemas encuentran patrones en la información y van cambiando su comportamiento conforme reciben más datos. Es parecido a cómo aprendemos los humanos de la experiencia.




Figura 3. Modelo de aprendizaje automático que relaciona la edad del niño con su altura mediante datos de entrenamiento. La curva celeste representa el modelo entrenado que predice la altura para cualquier edad.

Fuente: [29].

Una técnica importante es el aprendizaje por refuerzo. Funciona por prueba y error. Un agente digital interactúa con su entorno, toma decisiones, y recibe feedback en forma de recompensas o castigos. Con este ciclo va mejorando su estrategia hasta que optimiza sus resultados.

Ahora, las técnicas de deep learning son las más potentes. Usan redes neuronales artificiales que están inspiradas en cómo funciona el cerebro. Estas arquitecturas han cambiado por completo áreas como reconocer imágenes, procesar lenguaje y generar contenido multimedia.

b. Aprendizaje supervisado (Regresión lineal, logística y redes neuronales) [29]

El aprendizaje supervisado es probablemente la forma más fácil de entender dentro del machine learning, ya que se parece bastante a cómo aprendemos los humanos con la guía de un profesor. Básicamente, en lugar de decirle a la computadora qué hacer paso a paso, lo que se hace es mostrarle muchos ejemplos para que aprenda por sí misma. Es como si tuviera un cuaderno lleno de ejercicios (x) y sus respuestas correctas (y).

La idea no es que el modelo memorice todo, sino que sea capaz de encontrar la relación o el patrón que conecta cada caso con su solución. En este proceso, el sistema va probando, se

equivoca, compara su resultado con el correcto y luego ajusta sus parámetros internos para reducir el error la próxima vez. Es una especie de aprendizaje por ensayo y error, pero guiado.

En los casos más simples, esos patrones pueden representarse con cosas como una línea recta (regresión lineal) o una frontera que separa dos grupos (regresión logística). Sin embargo, cuando los problemas son más complejos como reconocer imágenes o interpretar lenguaje natural se usan modelos más potentes, como las redes neuronales. Estos modelos intentan imitar la forma en que el cerebro humano organiza la información y aprende de ella, lo que les permite capturar relaciones mucho más profundas y abstractas entre los datos.

c. Aprendizaje no supervisado [29] [Agregar Tipos]

Mientras que el aprendizaje supervisado opera con datos etiquetados, el aprendizaje no supervisado enfrenta un desafío más complejo y, en cierto sentido, más cercano a la cognición humana: descubrir estructuras subyacentes en datos sin clasificar. En este escenario, el modelo no recibe respuestas correctas ni incorrectas; simplemente debe explorar los datos y extraer patrones significativos por sí mismo.

Es importante notar que dentro de este paradigma existe un interés particular en los modelos generativos. Los modelos generativos no solo analizan información. La entienden tan bien que pueden crear ejemplos nuevos que mantienen las características esenciales de los datos originales. Digamos que capturan la "esencia" de lo que aprendieron.

Un ejemplo clásico es el algoritmo k-means. Sirve para agrupar cosas. Imagínate que tienes una biblioteca completamente desordenada y necesitas organizarla en K categorías. El algoritmo revisa cada libro (cada dato) y lo pone en el grupo que más le corresponde. Después de varias vueltas, terminas con grupos coherentes donde todo lo que está junto tiene cosas en común. Eso es básicamente el objetivo del aprendizaje no supervisado: encontrar la estructura escondida en los datos sin que nadie le diga cómo hacerlo.

d. Deep learning [29]

El deep learning es una de las áreas más avanzadas del machine learning. Se enfoca en entrenar redes neuronales profundas que tienen muchas capas de procesamiento. Por eso se llaman "profundas": tienen varias capas entre donde entran los datos y donde sale el resultado.

Cada capa tiene su función específica en la jerarquía de aprendizaje. Las primeras capturan características básicas de los datos. Las siguientes van combinando esos rasgos simples para identificar patrones cada vez más complejos. Es como una cadena donde cada eslabón transforma la información a un nivel más abstracto.




Figura 4. Ejemplo de variables latentes en un modelo generativo. Estas variables de baja dimensión se transforman mediante una red profunda para generar datos observados de alta dimensión a partir de una distribución simple.

Fuente: [29].

Un ejemplo: el reconocimiento de caras. Las primeras capas detectan cosas primitivas como bordes y colores. Las de en medio identifican partes específicas como ojos, nariz o boca. Las últimas logran reconocer la cara completa. Esta capacidad de aprendizaje jerárquico es lo que hace al deep learning tan poderoso para modelar información compleja.

Por eso el aprendizaje profundo es la base de muchos avances actuales en IA. Desde reconocimiento de voz y traducción automática hasta modelos que generan texto e imágenes.

e. CNN [29]

Las CNN están diseñadas específicamente para trabajar con datos visuales como imágenes y videos. Lo que las hace diferentes es cómo analizan la información. No procesan toda la imagen de golpe. La examinan por partes, encontrando patrones locales que después juntan para tener una visión completa.




Figura 5. Convolución unidimensional con kernel de tamaño tres. Cada salida se obtiene como una combinación ponderada de las entradas vecinas. Se muestran dos métodos para tratar los bordes: zero padding y convolución válida.

Fuente: [29].

Usan filtros (también llamados kernels) que se mueven sobre la imagen analizando pedazos pequeños. Van detectando características básicas: bordes, texturas, contrastes. Mientras la información avanza por las diferentes capas, esas características simples se van combinando y permiten reconocer cosas más complejas. Una capa detecta líneas o curvas. Otra distingue formas u ojos. Las capas finales hasta pueden reconocer caras completas.

Esta estructura jerárquica hace que las CNN sean muy eficientes y precisas para cualquier dato que esté organizado como una cuadrícula. Por ejemplo, matrices de píxeles o secuencias de video.

f. RNN [29]

Las RNN son diferentes porque pueden procesar información secuencial, donde el orden importa mucho. Son perfectas para analizar texto, audio o cualquier señal que se desarrolle en el tiempo.




Figura 6. Esquema de una red neuronal recurrente (RNN), donde los embeddings de palabras se procesan secuencialmente y cada paso transmite información al siguiente, capturando el contexto de la oración.

Fuente: [29].

Lo especial de las RNN es que tienen una especie de memoria interna. Les permite recordar información de los elementos que ya procesaron. O sea, no solo miran un dato aislado (como una palabra suelta en una frase). También toman en cuenta el contexto de lo que vino antes. Por eso pueden interpretar el significado de una palabra o un sonido considerando lo que pasó previamente en la secuencia.

Este funcionamiento basado en dependencias temporales hace que las RNN sean super útiles en tareas como traducción automática, análisis de sentimientos o generación de texto. En todas esas aplicaciones es esencial entender cómo se relacionan los elementos a lo largo del tiempo.

g. Autoencoders [29]

Los Autoencoders son modelos que aprenden a representar datos de forma eficiente sin supervisión. Su objetivo principal es encontrar una forma compacta de representar información. Primero la comprimen y después la reconstruyen tratando de que quede lo más parecida posible al original.

La arquitectura tiene dos partes. El codificador (encoder) transforma los datos de entrada (por ejemplo una imagen) en una representación comprimida más pequeña. El decodificador (decoder) intenta reconstruir la información original a partir de esa versión comprimida.




Figura 7. Comparación de enfoques para el ajuste de modelos generativos. a) Los modelos adversarios generan muestras que se vuelven más realistas con el entrenamiento. b) Los modelos probabilísticos, como los autoencoders variacionales y los modelos de difusión, aprenden la distribución de los datos para generar nuevos ejemplos.

Fuente: [29].

En este proceso de comprimir y reconstruir, el modelo aprende a capturar lo más importante de los datos mientras descarta lo que es redundante o ruido. Por eso sirve para cosas como reducir dimensionalidad, detectar anomalías o generar datos sintéticos.

Existe una versión más avanzada llamada Autoencoder Variacional (VAE). Introduce conceptos probabilísticos en el aprendizaje. Esto le permite generar muestras nuevas realistas a partir de lo que aprendió. Amplía mucho su aplicabilidad en el campo del aprendizaje generativo.

h. Transformers [29]

Los Transformers son un tipo de red neuronal que al principio se creó para procesar lenguaje natural. Pero después su influencia se extendió a muchas otras áreas del aprendizaje profundo. Lo que los hace especiales es el mecanismo de autoatención (self-attention). Esta técnica permite al modelo identificar qué partes de la entrada son más relevantes cuando procesa cada elemento.

A diferencia de las redes recurrentes que procesan datos paso a paso, los Transformers analizan toda la secuencia al mismo tiempo. Establecen conexiones directas entre elementos aunque estén muy alejados. Esto les da grandes ventajas en eficiencia computacional y capacidad para capturar dependencias complejas.




Figura 8. Arquitectura del modelo Transformer. El sistema recibe una matriz con los embeddings de las palabras y produce otra del mismo tamaño. Su estructura incluye bloques de atención múltiple, normalización por capas y conexiones residuales que permiten la interacción entre palabras y la preservación de la información original.

Fuente: [29].

Dentro de cada capa, los Transformers combinan varios bloques de autoatención que trabajan en paralelo (se llaman multi-head self-attention) junto con una red feed-forward que refina la información. También incorporan conexiones residuales y un proceso de normalización por capas (LayerNorm) que ayudan a mantener estabilidad durante el entrenamiento y mejoran cómo fluye la información entre capas.

Con esta arquitectura, los Transformers pueden procesar secuencias de cualquier longitud de forma muy eficiente. Por eso se han vuelto la base de muchos avances revolucionarios en IA. Desde modelos de lenguaje enormes hasta aplicaciones de visión por computadora.

i. Mecanismo de Autoatención [29]

El mecanismo de autoatención es el corazón de la arquitectura Transformer. La idea es elegante y potente a la vez. En vez de procesar una secuencia palabra por palabra de forma lineal (como hacían las arquitecturas viejas), la autoatención le da al modelo la capacidad de ver toda la oración al mismo tiempo. Para cada token de entrada, se crean tres vectores: una consulta (query), una clave (key) y un valor (value). Estos se obtienen mediante transformaciones lineales con parámetros que el modelo aprende. La salida para una posición específica se calcula como una suma ponderada de todos los vectores de valor de la secuencia. Los pesos de esta suma, que se conocen como atención, se obtienen calculando la similitud (generalmente mediante un producto punto escalado) entre el vector de consulta de la posición actual y los vectores de clave de todas las demás posiciones, seguida de una función softmax para normalizar los pesos. Este mecanismo le permite al modelo identificar relaciones y dependencias que pueden encontrarse incluso entre elementos muy alejados entre sí, comprendiendo el contexto a partir del contenido mismo de los datos y no únicamente por su posición.

j. BERT [29]

BERT, cuyo nombre completo es “*Representaciones de Codificador Bidireccional de Transformers*”, marcó un hito en la forma en que las máquinas interpretan el lenguaje humano. Su principal innovación radica en la capacidad de leer y comprender el texto en ambas direcciones al mismo tiempo, algo que los modelos anteriores no podían hacer. Mientras que las arquitecturas tradicionales analizaban una oración solo de izquierda a derecha o de derecha a izquierda, “BERT la analiza por completo, considerando simultáneamente el contexto que viene antes y después de cada palabra” [29]. Gracias a esta bidireccionalidad, el modelo logra captar matices semánticos y relaciones profundas entre palabras que antes pasaban desapercibidas.




Figura 9. Proceso de preentrenamiento en modelos tipo BERT. Los tokens de entrada, junto con el token especial <cls>, se transforman en embeddings y se procesan mediante capas Transformer. Algunos tokens se reemplazan por <mask> y el modelo aprende a predecir las palabras faltantes usando el contexto completo de la secuencia.

Fuente: [29].

El proceso de entrenamiento de BERT se desarrolla en dos etapas fundamentales: el *pre-entrenamiento* y el *ajuste fino (fine-tuning)*.

1. Pre-entrenamiento

a. Construcción del conocimiento fundamental

En la primera fase, BERT se expone a cantidades masivas de texto. Por ejemplo, todo Wikipedia. El objetivo es que aprenda solo la estructura y las reglas del lenguaje. Como dicen los investigadores, "no se le enseña a realizar una tarea específica, sino a 'entender'". Este proceso usa dos estrategias principales:

b. Modelado de Lenguaje Enmascarado (MLM):

Esta técnica oculta aleatoriamente algunas palabras de una oración. El modelo tiene que predecirlas usando solo el contexto que las rodea. Es como un ejercicio de "completar los espacios en blanco". Así BERT desarrolla una comprensión profunda de la gramática y el significado.

c. Predicción de la Siguiente Oración (NSP):

Aquí el modelo recibe dos oraciones. Tiene que determinar si la segunda es una continuación lógica de la primera o si no tienen relación. Con este mecanismo, BERT aprende a manejar la coherencia y el flujo natural del texto.

Al terminar esta etapa, el modelo ha internalizado un conocimiento general y robusto del lenguaje. Comparable al de un lector experimentado que ha asimilado miles de estructuras y relaciones semánticas.

2. Ajuste fino (Fine-Tuning): la especialización del modelo

En la segunda fase, el modelo pre-entrenado se adapta a tareas específicas. Este proceso es más breve y requiere una menor cantidad de datos, ya que BERT aprovecha la comprensión previa adquirida. Como se explica en la documentación, “se toma el modelo preentrenado, se le añade una pequeña capa de salida diseñada para la nueva tarea [...] y se le entrena un poco más con un conjunto de datos mucho más pequeño y etiquetado”.

De esta manera, el modelo puede especializarse rápidamente en distintos tipos de aplicaciones: análisis de sentimientos, clasificación de textos, respuestas automáticas o identificación de entidades legales, entre muchas otras. Esta combinación de un entrenamiento masivo y una adaptación dirigida es la razón por la que BERT se considera una de las arquitecturas más influyentes y versátiles en el procesamiento del lenguaje natural.

k. GPT [29]

“Los modelos GPT (Transformadores Generativos Pre-entrenados) son una familia de modelos de lenguaje cuyo superpoder es la generación de texto coherente y contextualizado”[29]. Están basados en la arquitectura del "decodificador" de Transformer, y su forma de operar es fundamentalmente autorregresiva. Pensemos en ello como si fuera un escritor muy metódico: para decidir cuál será la siguiente palabra de una oración, solo puede mirar las palabras que ya ha escrito. No puede "ver el futuro" de la frase. Para lograr esto técnicamente, utiliza un truco llamado autoatención enmascarada, que básicamente le pone una venda en los ojos para que, al

predecir la palabra en la posición 'X', solo pueda prestar atención al contexto que vino antes, desde la posición 1 hasta la 'X-1'.




Figura 10. Entrenamiento de una red decodificadora tipo GPT-3. Los tokens de entrada, precedidos por el token <start>, se transforman en embeddings y se procesan mediante capas Transformer con atención enmascarada. Cada posición solo puede usar el contexto previo para predecir el siguiente token, optimizando la probabilidad del texto siguiente en la secuencia.

Fuente: [34].

La verdadera revolución llegó con modelos a una escala masiva, como GPT-3, que cuentan con cientos de miles de millones de parámetros. Este tamaño colosal les otorgó una habilidad emergente casi mágica conocida como few-shot learning (aprendizaje de pocos ejemplos). Esto significa que, en lugar de necesitar un re-entrenamiento completo para una nueva tarea, a menudo es suficiente con darle al modelo unas pocas demostraciones de lo que quieres directamente en la instrucción (prompt). Es como mostrarle a un genio un par de ejemplos resueltos de un problema que nunca ha visto; basándose en esos pocos ejemplos, es capaz de entender la lógica y resolver el siguiente por su cuenta, sin necesidad de volver a estudiar.

1. Entrenamiento semi supervisado[29]

El entrenamiento semi-supervisado es una estrategia ingeniosa que aprovecha lo mejor de dos mundos. Imagina que tienes una pequeña cantidad de datos con respuestas claras (etiquetados) y una montaña de datos sin ninguna respuesta (no etiquetados). En lugar de desechar la información sin etiqueta, este enfoque los utiliza a ambos. El modelo se entrena simultáneamente

con los dos conjuntos de datos. La idea es que los pocos ejemplos etiquetados actúen como "pistas" o "semillas" de conocimiento, mientras que la gran cantidad de datos no etiquetados revelan la estructura y los patrones ocultos del problema en general. Al analizar cómo se distribuyen y agrupan todos los datos en conjunto, el modelo puede hacer deducciones inteligentes para "adivinar" las etiquetas de los datos que no las tenían. Es importante destacar que, en este contexto, el objetivo no es crear una regla universal que funcione para datos futuros que el modelo nunca ha visto. Más bien, el objetivo es completar el rompecabezas que se tiene entre manos: inferir las etiquetas para los datos no etiquetados que formaron parte de su propio entrenamiento, aprovechando toda la información disponible desde el principio.

m. Agents en aprendizaje por refuerzo [29]

En el aprendizaje por refuerzo, el protagonista es el agente. Podemos pensarlo como un aprendiz digital. Puede ser el personaje de un videojuego, un brazo robótico o un algoritmo que opera en la bolsa. Su misión es aprender a tomar las mejores decisiones posibles en su entorno.

El proceso de aprendizaje es un ciclo continuo. Muy similar a prueba y error:

- Observar: El agente primero mira alrededor para entender la situación actual (el "estado").
- Actuar: Después de analizar su entorno, selecciona una acción que considera adecuada en ese momento.
- Retroalimentación: Una vez que actúa, el entorno responde. Cambia de estado y le entrega una recompensa. Esta recompensa es un número que indica si su elección fue buena o mala.

El propósito fundamental del agente no es solo maximizar recompensas inmediatas. Es optimizar la acumulación total de beneficios a lo largo del tiempo. Para esto, el agente necesita desarrollar una política. Una estrategia que le guíe en cada situación.

El proceso enfrenta un dilema permanente: el trade-off exploración-explotación. Por un lado, explorar significa probar acciones nuevas esperando descubrir estrategias mejores. Por otro lado, explotar significa repetir acciones que ya dieron buenos resultados. Muchas veces se usan redes neuronales profundas como el núcleo del agente. Establecen una relación directa entre lo que observa del entorno y las decisiones que toma. Funcionan como su "cerebro" de aprendizaje.

[Teoría de Metodología]

a. Scrum [30]

Scrum es una metodología colaborativa que promueve adaptabilidad y mejora continua ante cambios. No es como los enfoques tradicionales que se basan en planes exhaustivos y rígidos. Scrum es iterativo y flexible. La idea es que equipos pequeños y multidisciplinarios desarrollen partes funcionales de un proyecto en ciclos cortos.

El proceso empieza creando un Product Backlog. Es una lista priorizada de tareas o requisitos. Estas tareas se dividen en iteraciones llamadas Sprints que duran entre una y cuatro semanas típicamente. Al terminar cada Sprint, el equipo presenta un incremento del producto que funciona y puede evaluarse o entregarse.

Este enfoque tiene beneficios importantes. Primero, facilita comunicación constante con el cliente. Puede revisar el progreso real y ajustar prioridades en cada ciclo. Segundo, fomenta la reflexión del equipo mediante la retrospectiva. Es una reunión donde analizan aciertos y áreas de mejora para los siguientes Sprints.

b. Kanban [30]

Kanban es una forma súper práctica de organizar el trabajo, sobre todo cuando quieres que las cosas fluyan sin caos. Imagina un equipo que está desarrollando una app: en lugar de abrumarse con mil tareas a la vez, Kanban les ayuda a mantener todo bajo control con tres ideas clave.

La primera es usar un tablero visual, como un pizarrón con post-its o una herramienta digital como Trello. Cada tarea es una tarjeta que se mueve por columnas como 'Pendiente', 'En proceso' o 'Listo'. Así, todos saben en qué está el proyecto. La segunda es no intentar hacer todo al mismo tiempo. Kanban pone un límite a cuántas tareas puedes tener en cada columna, para que no termines con un cuello de botella o un equipo agotado. Y la tercera es medir cuánto tardas en terminar cada tarea (lo que llaman lead time) para ir puliendo el proceso y ser más rápido sin sacrificar calidad.

Lo mejor de Kanban es que no te obliga a seguir reglas estrictas. Es más como una filosofía que te invita a mejorar poco a poco, adaptándote a lo que tu equipo necesita.

c. Límite de Trabajo en Progreso (WIP) [30]

Aunque Scrum y Kanban comparten el principio de limitar el WIP, lo hacen diferente. En Scrum, el límite es implícito a través del Sprint. Al inicio de cada iteración, el equipo define tareas que se compromete a completar. Actúa como límite natural porque no se agrega trabajo nuevo hasta el siguiente Sprint.

Kanban es más explícito y granular. No restringe la cantidad total de trabajo por ciclo. Establece límites específicos para cada etapa del flujo. Cada columna del tablero Kanban (por ejemplo "En desarrollo" o "En pruebas") puede tener un número máximo de tareas permitidas. Si se supera, se identifica inmediatamente el cuello de botella. El equipo puede enfocarse en resolver bloqueos antes de continuar con tareas nuevas.

d. Iteraciones Fijas (Sprints) vs. Flujo Continuo [30]

Una diferencia fundamental está en el ritmo de trabajo. Scrum estructura todo en bloques de tiempo con duración fija y estricta: los Sprints. Cada Sprint combina planificación, desarrollo y (idealmente) una entrega de software funcional. El alcance se define al inicio y se busca no cambiarlo.

Kanban no prescribe iteraciones fijas. Permite que planificación, entrega y mejora del proceso ocurran en cadencias separadas o sean impulsadas por eventos. Por ejemplo, la planificación puede pasar cuando el equipo está por quedarse sin trabajo. Una entrega puede hacerse apenas una funcionalidad esté lista. Esto da más flexibilidad para responder a cambios de prioridad. Los nuevos ítems pueden introducirse en el flujo tan pronto haya capacidad disponible.

e. Tableros Visuales: Scrum Board vs. Kanban Board [30]

Ambas metodologías utilizan tableros visuales para gestionar el trabajo, pero su propósito y ciclo de vida son distintos. Un Scrum Board está asociado a un único equipo multifuncional y su alcance se limita a las tareas de un solo Sprint. Al final de cada iteración, el tablero se resetea y se vuelve a poblar con los ítems del siguiente Sprint. Su propósito es que el equipo gestione su compromiso para esa iteración específica. Por otro lado, un Kanban Board es persistente y representa todo el flujo de trabajo, desde la concepción de una idea hasta su entrega final. No se resetea y puede ser compartido por múltiples equipos o especialistas. Incluye límites de WIP explícitos por columna para gestionar el flujo.

f. Naturaleza Empírica y Mejora Continua (Kaizen) [30]

Tanto Scrum como Kanban son procesos empíricos, lo que significa que se espera que los equipos experimenten y adapten continuamente el proceso a su entorno específico. Ninguno de los dos proporciona todas las respuestas, sino que ofrecen un conjunto de restricciones para impulsar la mejora. Este principio se conoce como "Inspeccionar y Adaptar" en Scrum y se alinea con el principio Lean de Kaizen (mejora continua). El mecanismo central es el ciclo de retroalimentación: cambiar algo en el proceso, observar los resultados en métricas como la capacidad o el lead time, aprender de la observación y volver a cambiar. En Scrum, el Sprint en sí mismo es el ciclo de retroalimentación básico, mientras que Kanban proporciona métricas en tiempo real que permiten ciclos de retroalimentación más cortos y flexibles.

g. Roles Prescritos vs. Flexibilidad de Roles [30]

Scrum es más prescriptivo en cuanto a los roles, definiendo tres específicos: el Product Owner (responsable de la visión y prioridades del producto), el Equipo (que implementa el producto) y el Scrum Master (que elimina impedimentos y lidera el proceso). Estos roles están claramente definidos para asegurar una distribución de responsabilidades. Kanban, en cambio, no prescribe ningún rol en absoluto. Esto no significa que no puedan existir roles como un Product Owner, sino que el método no los exige, dejando la estructura del equipo abierta a las necesidades del contexto. La mentalidad general en ambas metodologías es "menos es más", por lo que se recomienda comenzar con una estructura simple y añadir roles solo si realmente aportan valor.